

Sistemas de deteção de intrusão (IDS)





Índice

- Introdução
- Conjuntos de dados
- Modelos de Machine Learning
- Prova de conceito
- Conclusão

Introdução

- **Transição Teoria-Prática:** Foco na construção e validação de um IDS funcional.
- **Objetivo:** Demonstração da eficácia em tempo real na identificação de tráfego malicioso.
- **Superar Limitações Tradicionais:** Adoção de Machine Learning (ML) para melhor desempenho.
- **Escalabilidade e Complexidade:** Análise eficiente de elevado volume de dados a alta velocidade.
- **Adaptabilidade Dinâmica:** Elevada eficácia de modelos (Decision Tree e Random Forest) na distinção de ataques.

Conjunto de dados - Seleção

- Utilização do *sub-conjunto* "Wednesday-workingHours" do conjunto de dados CIC-IDS2017, reconhecido pelo tráfego de rede realista (benigno e malicioso) e complexidade computacional reduzida para treino eficiente.
- Composição do Tráfego: Tráfego Benigno e vários ataques DoS (Hulk, GoldenEye, Slowloris, Slowhttptest) e Heartbleed.
- Desequilíbrio de Classes significativo e necessidade crítica de técnicas de pré-processamento para garantir a eficácia


Conjunto de dados - Pré-processamento

1. Codificação e Normalização

- **Codificação:** Conversão da variável alvo de categórica para numérica.
- **Normalização:** Ajuste de todas as *features* numéricas para o intervalo [0,1]

2. Estratégia de Divisão

- **Divisão Treino-Teste:** 80% Treino / 20% Teste
- **Undersampling:** Redução da classe maioritárias
- **SMOTE (Oversampling):** Gerar amostras sintéticas das classes minoritárias.






Modelos de Machine Learning

- Decision Tree
- Random Forest
- XGBoost

Decision Tree


Métrica	Valor
Accuracy	0.99941534
Precisão	0.99941964
Recall	0.99941534
F1-score	0.99941669

False Positives - 51
False Negatives - 12



Random Forest

Métrica	Valor
Accuracy	0.99937925
Precisão	0.99937958
Recall	0.99937925
F1-score	0.99937927




False Positives - 57
False Negatives - 11

XGBoost

Métrica	Valor
Accuracy	0.99837593
Precisão	0.99837878
Recall	0.99837593
F1-score	0.99837407

False Positives - 153
False Negatives - 53



Prova de Conceito - Modelo escolhido

- **Decision Tree** , métricas excelentes e baixo custo computacional
- **Random Forest**
- **XGBoost**

Prova de Conceito - Arquitetura

- **Ambiente:** O sistema é dividido entre duas máquinas:
 - **Host (Windows):** Simulação e injeção de tráfego de ataque.
 - **VM (Linux/Kali):** Execução do pipeline IDS
- **Pipeline de Detecção (3 Fases)**
 - **Captura (VM):** Interseção e recolha do tráfego de rede
 - **Feature Engineering (VM):** O tráfego bruto é convertido em features pelo CICFlowMeter.
 - **Classificação (VM):** As features são normalizadas e o modelo Decision Tree atribui um rótulo de ataque ou benigno.

Prova de Conceito - Ferramentas

- **Máquina virtual**

- **Tshark:** Utilizado para Captura de Pacotes na interface de rede e gravação num ficheiro temporário .pcap
- **CICFlowMeter (CFM):** Motor de Extração de Features. Processa o .pcap para gerar as features
- **Ecosistema Python:** Ambiente que utiliza pandas (manipulação de dados), scikit-learn (modelo) e joblib (carregamento de artefatos).

- **Máquina Anfitriã**

- **Scapy:** Biblioteca Python essencial para Simulação de Tráfego. Lê o PCAP de ataque e injeta os pacotes na rede Host-Only.
- **Npcap:** Driver de Rede que permite que o Scapy aceda ao raw socket e envie os pacotes diretamente pela interface de rede.

Prova de Conceito - Scripts

- Script de envio (Máquina Anfitriã)
 - Estabelece a ligação à Host-Only Network Adapter
 - Reproduz os pacotes do ficheiro PCAP de teste, direcionando-os à VM
- Script IDS (Máquina Virtual)
 - Executa o Tshark para captura de pacotes
 - Executa o CICFlowMeter para gerar features
 - Invoca o script de classificação

Prova de Conceito - Desafios e Resultado

- **Desafios de Validação**

- Foi impossível comparar o output obtido com os rótulos reais do dataset original
- Impacto no Modelo: A incapacidade impediu o cálculo preciso das métricas de desempenho e o afinamento e otimização do modelo
- Validação de Script: A falta de resultados totalmente conclusivos também limitou a correção e o refinamento do script de classificação

- **Fluxo de Execução**

- Foi estabelecido com sucesso um fluxo de execução de ponta-a-ponta totalmente funcional.
- Validou-se a integração perfeita de ferramentas díspares (Scapy, Tshark, CICFlowMeter e o modelo ML) numa única pipeline automatizada.
- Demonstrou-se a viabilidade do conceito de MLIDS na arquitetura de duas máquinas.

Prova de Conceito - Trabalho Futuro

- **Refinamento e Robustez**
 - **Implementação de Mapeamento Real:** Desenvolver um mecanismo para comparar diretamente os flows classificados na VM com o dataset original
 - **Evolução do Script e Modelo:** Com os resultados verificáveis, o script de classificação e o modelo ML podem desta forma ser otimizados e evoluídos
- **Automação e Estabilidade**
 - **Monitorização Contínua:** Melhorar o *script* Bash para um **ciclo contínuo** e permitir que o sistema opere como um IDS em tempo quase real

Conclusão

- Avaliação de modelos treinados com dataset CIC-IDS 2017
- Prova de Conceito Implementada
- Integração de diferentes ferramentas como scapy, tshark e cicflowmeter

Exemplo execução

```
PS C:\Users\pc\Downloads> python3 ids.py
[*] A iniciar leitura do ficheiro PCAP grande (Limite: 50000 pacotes)
[*] A enviar pacotes via streaming na interface: Ethernet 2...
[*] Pacotes enviados: 50000
[+] Replay concluído.
[+] Total de pacotes enviados: 50000
[+] Duração: 80.53 segundos
```

Máquina Anfitriã

```
(auser@osboxes)-[~]
$ ./full_ids_run.sh
— 1. INICIO DA CAPTURA COM TSHARK —
[sudo] password for auser:
Sorry, try again.
[sudo] password for auser:
Running as user "root" and group "root". This could be dangerous.
Capturing on 'eth0'
40646
^C
Captura encerrada com sucesso.
— 2. PROCESSANDO PCAP (CICFlowMeter) —
cic.cs.unb.ca.ifm.Cmd You select: /tmp/
cic.cs.unb.ca.ifm.Cmd Out folder: /home/auser/
CICFlowMeter found :1 pcap files
⇒ 1 / 1
Working on... ataque_capturado_teste.pcap
ataque_capturado_teste.pcap is done. total 848 flows
Packet stats: Total=40646,Valid=39887,Discarded=759
```

```
— 3. CLASSIFICAÇÃO DOS FLOWS (IDS Python) —
/home/auser/ids_venv/lib/python3.13/site-packages/sklearn/base.py:442: Incons
istentVersionWarning: Trying to unpickle estimator DecisionTreeClassifier fro
m version 1.5.1 when using version 1.7.2. This might lead to breaking code or
invalid results. Use at your own risk. For more info please refer to:
https://scikit-learn.org/stable/model_persistence.html#security-maintainabili
ty-limitations
warnings.warn(

[*] A carregar e pré-processar dados de /home/auser/ataque_capturado_teste.pc
ap_Flow.csv ...
→ Inserir 1 feature(s) em falta com valor 0.

[*] Previsões ...

— RELATÓRIO DE DETEÇÃO DE INTRUSÃO (Decision Tree) —
Predicted_Label
Benign          495
Dos Hulk        247
DoS GoldenEye   58
DoS slowloris   47
Name: count, dtype: int64

[!!!] ALERTA: ATAQUE(S) DETETADO(S)! [!!!]

Primeiros 5 Flows de Ataque:
```

	Flow ID	Predicted_Label
0	192.168.10.14-209.48.71.168-49459-80-6	Dos Hulk
2	192.168.10.3-192.168.10.17-88-46124-6	DoS GoldenEye
4	192.168.10.3-192.168.10.17-88-46126-6	Dos Hulk
6	192.168.10.3-192.168.10.17-88-46131-6	Dos Hulk
8	192.168.10.3-192.168.10.15-49666-49413-6	Dos Hulk

Máquina Virtual